Informe final — Proyecto 2 y 3: Análisis, Limpieza y Modelado

Siniestralidad vial en Santiago de Cali, 2016–2024 · Grupo DatosSinCiencia

1. Contexto del dataset y pregunta de negocio

El dataset reúne **370.996 reportes de siniestros de tránsito** recibidos por la Secretaría de Movilidad de Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024 (tras eliminar duplicados y una fila vacía). Cada registro indica la fecha, el resultado del reporte (`Tipo confirmado`), la dirección, la clase de accidente, el medio por el que se reportó y los vehículos implicados.

Pregunta de negocio: ¿qué características de un siniestro se asocian con su gravedad (solo daños, con lesionados o con fallecidos), para focalizar la prevención y priorizar la atención?

2. Resumen del análisis exploratorio

El análisis completo está en `entrega/fase_a_eda.ipynb` (15 gráficos, cada uno con su insight). Aquí se presentan los tres hallazgos más importantes.

Hallazgo 1 — Motociclistas y ciclistas concentran la gravedad

Siniestros que involucran…	Con lesionados	Con fallecidos	Casos
Bicicleta	**60,3%**	**3,2%**	1.307
Motocicleta	**42,7%**	**1,7%**	68.217
Transporte público	30,4%	1,0%	13.411
Vehículo de carga	13,7%	1,5%	10.483
Solo autos/camionetas	11,5%	0,3%	60.524

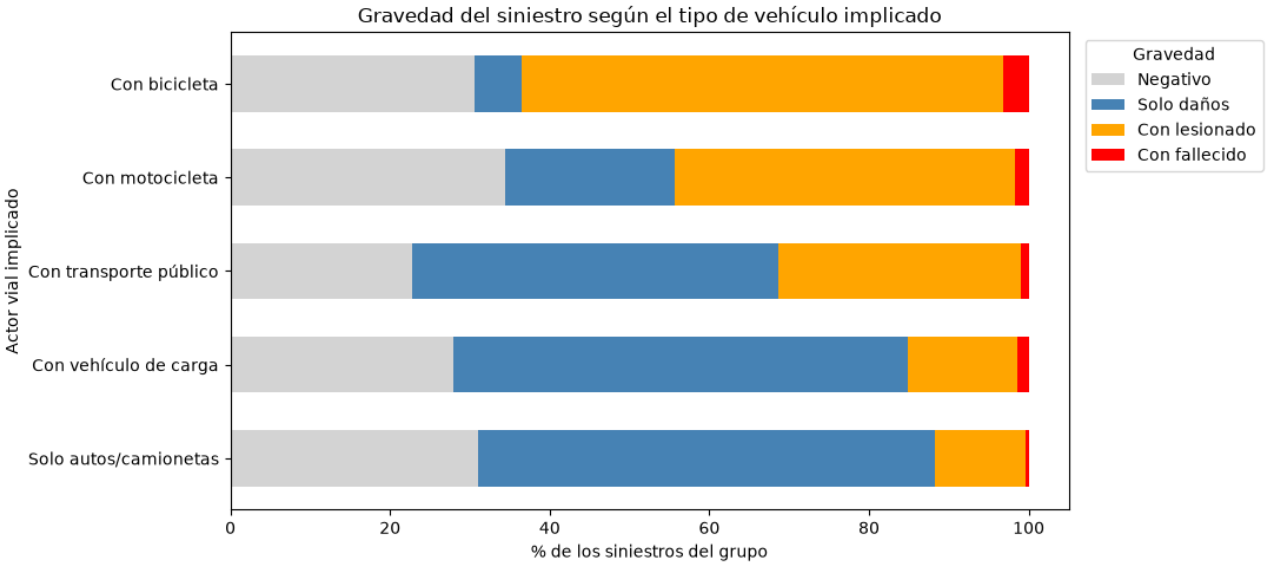


Figura 1. Gravedad del siniestro según el actor vial implicado (reportes con información de vehículos).

Un siniestro con moto es **5 veces más letal** que uno entre carros, y las motos están en el 46% de los siniestros con información de vehículos. Automóviles y motos suman el 84% de todos los vehículos implicados.

Para el negocio: las campañas, la infraestructura (carriles, cruces) y los controles con mayor

impacto en vidas son los dirigidos a motociclistas y ciclistas.

Para el proyecto: el tipo de vehículo es lo que más se asocia con la gravedad (Spearman +0,16 para motos y −0,23 para autos; las variables de calendario ≈ 0). Pero el dato de vehículos falta en el 81% de los reportes "Negativo" y solo en el 16–19% de los siniestros con daños o lesionados, porque se registra al confirmar el caso: sirve para explicar la gravedad entre siniestros confirmados, no para predecir si un reporte resultará "Negativo" (riesgo de fuga de datos).

Hallazgo 2 — Dos de cada tres reportes no terminan en un siniestro confirmado

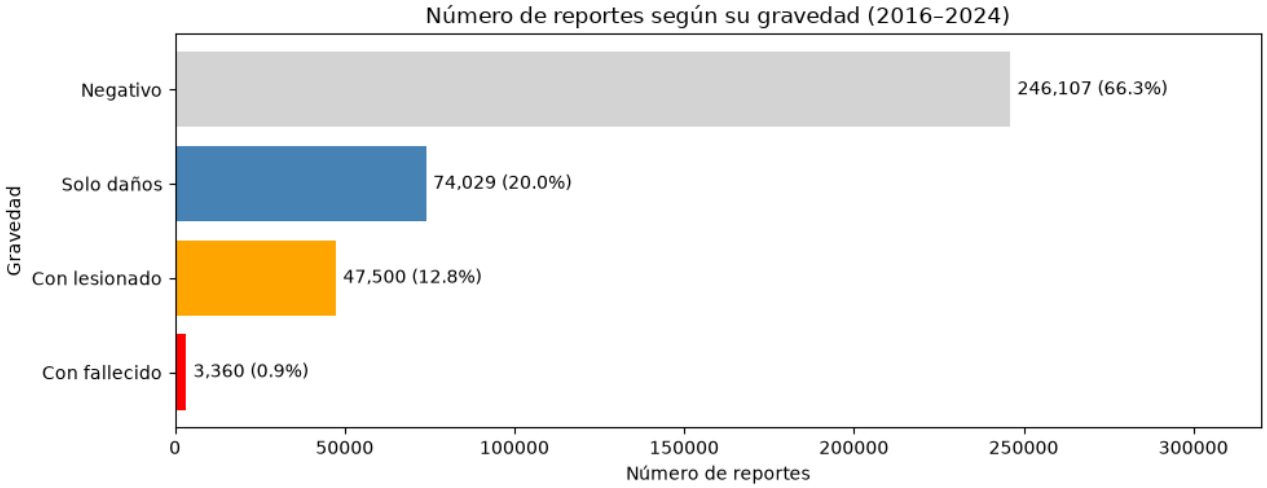


Figura 2. Distribución de los reportes según su resultado, 2016–2024.

El **66,3% de los reportes son "Negativo"**: el agente acude pero no se confirma un siniestro que requiera intervención (falsa alarma, los implicados no quieren intervención o ya se retiraron). El 20,0% son solo daños, el 12,8% con lesionados y apenas el **0,9% con fallecidos** (3.360 casos, ≈1 por día).

Para el negocio: la mayor parte del esfuerzo de atención se va en reportes que no requieren actuación, y el problema más costoso, los fallecidos, es también el menos frecuente: un indicador basado en el total de reportes lo esconde.

Para el proyecto: la variable objetivo está muy desbalanceada. Un modelo que diga siempre "Negativo" acierta el 66% sin servir para nada, por eso los modelos se comparan con Recall y F1 por clase, no solo con Accuracy.

Hallazgo 3 — El registro cambió con el tiempo: menos reportes no es una ciudad más segura

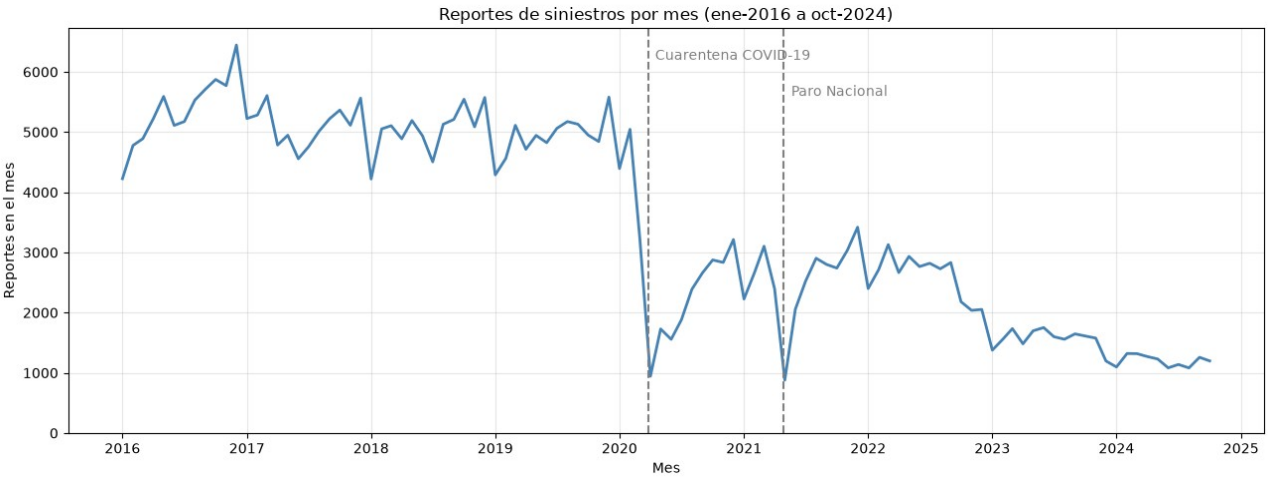


Figura 3. Reportes por mes, enero de 2016 a octubre de 2024.



Figura 4. Promedio diario de siniestros confirmados por gravedad y año (2024 llega hasta el 2 de noviembre).

- El volumen cae de ≈5.000 a ≈2.500 reportes al mes en marzo de 2020 (COVID-19) y nunca se recupera; en 2024 son ≈1.200 al mes. El Paro Nacional (30-abr a 4-may-2021) deja días con 1 a 5 reportes.
- Los siniestros "solo daños" pasan de 47 diarios (2019) a 1–2 diarios (2023–2024). Algunos reportes citan la Ley 2251 de 2022 para que los implicados resuelvan entre ellos los choques sin heridos.
- En cambio, **los siniestros con fallecido se mantienen en ≈1 por día (360–450 al año) entre 2016 y 2023**.
- Los faltantes dependen del año: la dirección no se registró en 2018–2020, el medio de reporte solo existe desde 2021 y la clase de accidente solo está casi completa en 2024.

Para el negocio: la caída de reportes refleja cambios en la forma de reportar, no una mejora equivalente de la seguridad vial; el indicador confiable para seguir el problema son los fallecidos. Mantener el mismo formulario año tras año es requisito para evaluar cualquier política.

Para el proyecto: los faltantes no son aleatorios, así que deben tratarse según el periodo y no imputarse con un solo valor para todo el rango de años.

Otros hallazgos de apoyo: el domingo tiene menos reportes pero la mayor proporción de víctimas (17,6%) y de fallecidos (1,4%, el doble que un jueves), y el lunes —día de la mayoría de festivos— es el segundo más letal; el volcamiento (3,8%) y el atropello (2,6%) son las clases de accidente más letales; dos de las "direcciones" con más reportes son clínicas, donde se registra el caso cuando llega el lesionado.